

1 Pistes de réflexion Thèse - Janvier 2015

1.1 Introduction

Soient X_1, \dots, X_n , $X_i \in \mathbb{R}^p$ un échantillon de n variables aléatoires i.i.d de loi P^* . On suppose que P^* est un mélange de K composantes Gaussiennes P_j , $j \in [K]$ et que K est connu:

$$P^* = \sum_{j=1}^K \pi_j P_j \quad \text{avec} \quad \forall i, \quad \pi_i > 0 \quad \text{et} \quad \sum_{j=1}^K \pi_j = 1$$


Où P_j a pour densité la loi normale $\mathcal{N}_p(\boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)$.

Une approche classique dans le cadre de mélange de gaussien est d'utiliser l'algorithme EM pour estimer les paramètres $\boldsymbol{\Pi} = (\pi_1, \dots, \pi_n), \boldsymbol{\mu}, \boldsymbol{\Sigma}$. Sans hypothèse supplémentaire, la complexité de cette approche rend le calcul impossible quand la dimension p devient grande. Une approche est de considérer $\boldsymbol{\Sigma}$ diagonale mais ceci revient à considérer que les features sont indépendantes ce qui est un inconvénient.

1.2 Approche par analyse structurelle de Σ

Soient Y_1, \dots, Y_n un échantillon de n variables aléatoires i.i.d de loi $\mathcal{N}_p(\boldsymbol{\mu}^*, \boldsymbol{\Sigma}^*)$, $Y_i \in \mathbb{R}^p$. Supposons p grand. Nous cherchons à estimer $\boldsymbol{\mu}^*$ et $\boldsymbol{\Sigma}^*$.

Nous pouvons estimer la moyenne empirique $\hat{\boldsymbol{\mu}} = \bar{Y}_n$ et donc supposer que $\boldsymbol{\mu} = 0$. Pour $\boldsymbol{\Sigma}^*$ ceci est plus délicat et nous chercherons des hypothèses structurelles sur $\boldsymbol{\Sigma}^{-1} = \boldsymbol{\Omega}$ la matrice de précision. Notamment en considérant que $\boldsymbol{\Omega}$ est creuse. Interprétation: si $\omega_{j,j'} = 0$ alors $Y^j \perp\!\!\!\perp Y^{j'} | \{Y^l \setminus (Y^j, Y^{j'})\}$. Nous pouvons considérer le graphe $G = (V, E)$ avec $\text{card}(V)=p$ alors,



et $e_{j,j'} \in E \iff \omega_{j,j'} \neq 0$

1.2.1 Graphical Lasso

On veut l'estimateur du maximum de vraisemblance pénalisé par la norme L_1 .

$$\hat{\Omega} \in \arg \min_{\Omega \geq 0} \left\{ \log(\det \Omega) + \frac{1}{2} \text{tr}(\Omega S_n) + \lambda \|\Omega\|_1 \right\}$$

avec $S_n = \frac{1}{n} \sum_{i=1}^n Y_i Y_i^T$ la matrice de covariance et $\|\Omega\|_1 = \sum_{j,j': j \neq j'} |\omega_{j,j'}|$
Ceci est un problème d'optimisation convexe, (problème d'optimisation SDP)

1.2.2 Column-wise Lasso

(Théorème) Si $Y \sim \mathcal{N}_p(0, (\Omega^*)^{-1})$, alors

$$Y_j = \sum_{j' \in [p] \setminus j} \left(-\frac{\omega_{jj'}^*}{\omega_{jj}^*} \right) Y^{j'} + \frac{1}{\sqrt{\omega_{jj}^*}} \xi^j$$

où $\xi^j \sim \mathcal{N}_p(0, 1) \perp \{Y^{j'} : j' \in [p] \setminus j\}$

1.2.3 Méthode d'estimation

$\forall j \in \{1, \dots, p\}$ on estime le vecteur $\frac{1}{\omega_{jj}} \begin{bmatrix} \omega_{j1} \\ \vdots \\ \omega_{jj} \end{bmatrix}$ On estime β par la méthode du

Lasso:

$$\hat{\beta} \in \arg \min_{\beta \in \mathbb{R}^{p-1}} \left\{ \|Y^j - Y^{-j} \beta_{-j}\|_2^2 + \lambda \|\beta_{-j}\|_1 \right\}$$

ou Y^{-j} matrice des $Y_{j'} \setminus Y_j$.

On pose

$$\hat{\omega}_{jj} = \left(\frac{\|Y^j - Y^{-j} \beta_{-j}\|_2^2}{n} \right)^{-1} \quad \text{et} \quad \hat{\omega}_{jj'} =$$

On a un lasso en dimension p , la théorie recommande:

$$\lambda = \sqrt{\frac{2 \log(p)}{n}} \frac{1}{\sqrt{\omega_{jj}^*}}$$

1.2.4 Square-root Lasso

$$\hat{\beta} \in \arg \min_{\beta \in \mathbb{R}^{p-1}} \{ \| Y^j - Y^{-j} \beta_{-j} \|_2 + \lambda \| \beta_{-j} \|_1 \}$$

la theorie recommande:

$$\lambda = \sqrt{\frac{2 \log(p)}{n}}$$

$$(\text{Theoreme}) \quad \forall \lambda > 0, \exists \lambda_1 > 0 \quad | \quad \hat{\beta}^{\sqrt{Lasso}}(\lambda) = \hat{\beta}^{Lasso}(\lambda_1)$$

1.3 Objectifs

Injecter cette méthode du column-wise lasso dans EM sous l'hypothese $\Omega_j = \Sigma_j^{-1}$ est creuse. Nous pourrons commencer par un cas simple, $\Omega_j = \Omega, \forall j$

1.4 Notation pratique

Nous pourrons utiliser la notation suivante:

$$\hat{\beta}^{Lasso} \in \arg \min_{\substack{\hat{B} \in \mathbb{R}^p \\ B_{jj}=1}} \{ \| Y \cdot \hat{B} \|_2^2 + \lambda \| \hat{B} \|_1 \}$$

avec $Y = [Y_1, \dots, Y_n]^T \in \mathbb{R}^{n,p}$ et $\| Y \hat{B} \|_2^2 = \sum_{j=1}^p \| Y \hat{B}_j \|_2^2$